To samo pytanie. Inny język. Inne źródła.

Czy język, w którym pytamy, zmienia źródła cytowane przez wyszukiwarki AI? Pilotaż: 30 pytań po polsku i po angielsku, każde zadane 5 razy w Perplexity (sonar) i OpenAI (gpt-6-luna z wyszukiwaniem), oba przez API, 23.10.2026.

Maciej Zmitrukiewicz Uniwersytet Ekonomiczny we Wrocławiu 194034@student.ue.wroc.pl

GŁÓWNY WYNIK W PERPLEXITY

to samo pytanie, ten sam język

96%

wspólnych domen w dwóch odpowiedziach

to samo pytanie, polski vs angielski

4%

wspólnych domen w dwóch odpowiedziach

Zmiana języka wymienia prawie cały zestaw cytowanych domen. Udział źródeł polskojęzycznych, PL vs EN: +94 p.p. (mediana pytań, 95% CI od +88 do +96); poza sprawami polskimi mediana ok. 95% po polsku i 0% po angielsku.

INNY WZORZEC W OPENAI (API)

56%

wspólnych domen, ten sam język

49%

wspólnych domen, PL vs EN

Język zmienia źródła niewiele: powtórzenia różnią się prawie tak samo jak języki. Poza sprawami polskimi polskie źródła pojawiały się rzadko.

26% odpowiedzi bez cytowań, przy wiedzy ogólnej 75%. Tam porównanie języków obejmuje tylko 3 z 10 pytań.

Uwaga przy porównaniu: wpływ języka oceniamy osobno w każdym systemie. API Perplexity zwraca listę źródeł, a API OpenAI odnośniki w odpowiedzi, więc wartości między systemami nie są bezpośrednio porównywalne. **Wspólne domeny:** wspólne / wszystkie domeny dwóch odpowiedzi (Jaccard), średnia par, mediana z 30 pytań.

PRZYKŁAD Z DANYCH

„Jak działa szczepionka mRNA?”

Perplexity, po polsku — **94% PL**

Narodowy Instytut Zdrowia Publicznego PZH, Medycyna Praktyczna, Europejska Agencja Leków

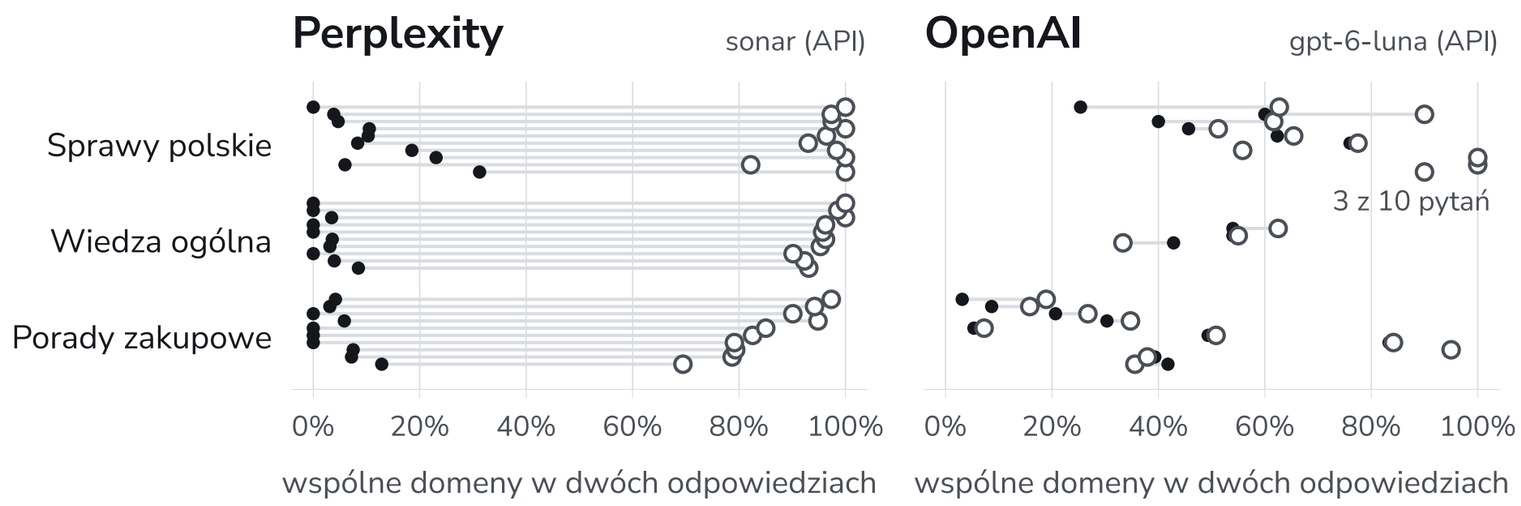
Perplexity, po angielsku — **0% PL**

CDC (USA), Cleveland Clinic (USA), NIH genome.gov (USA)

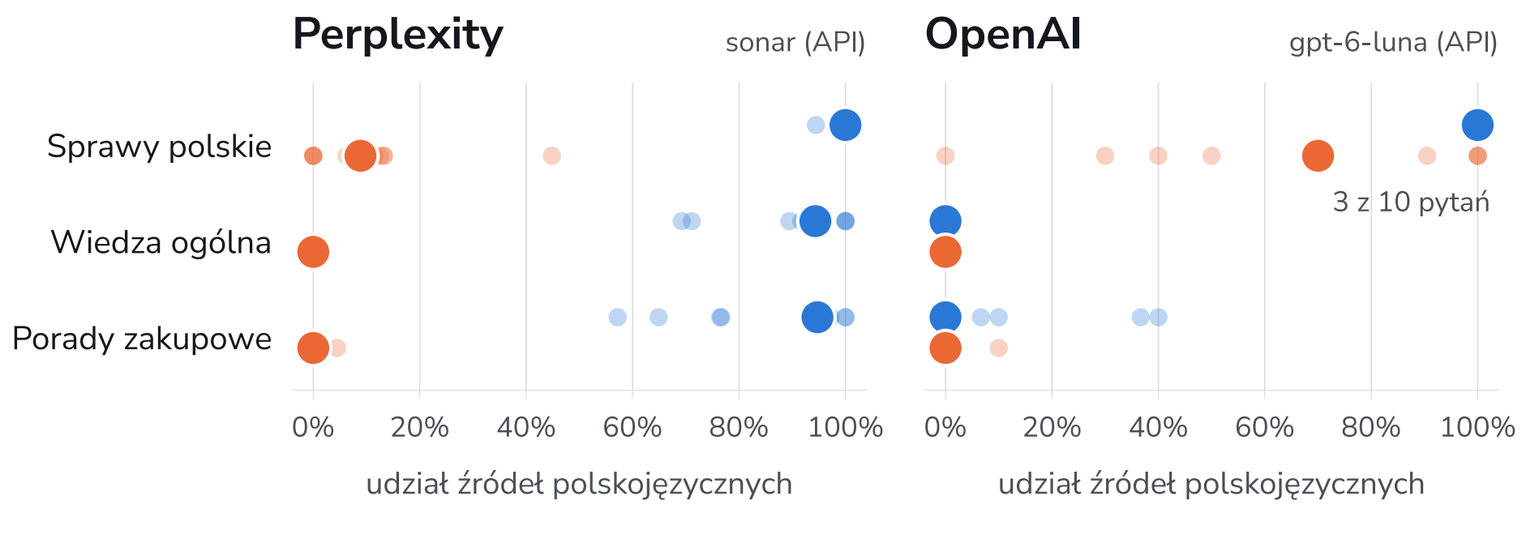
OpenAI, po polsku — **0% PL**

CDC (USA), WHO, MedlinePlus (USA)

Najczęściej cytowane źródła z 5 powtórzeń. Odpowiedź OpenAI była po polsku, cytowane strony po angielsku.



Rys. 1. Wspólne domeny w każdym z 30 pytań. Pierścień: rozrzut powtórzeń. Kropka: odpowiedź polska vs angielska. Długa linia: język zmienia źródła.



Rys. 2. Udział źródeł polskojęzycznych. Małe punkty: pytanie (średnia z 5 powtórzeń), duże: mediana. Odpowiedzi bez cytowań pominięte.

METODA I SPRAWDZALNOŚĆ

- 30 autorskich pytań w 3 grupach, każde 5 razy w blokach co ≥ 1 h (OpenRouter): 600 odpowiedzi, 1584 strony.
- Język źródła z treści strony (fastText), a gdy jej brak, z atrybutu lang lub tytułu (18%); bez klasyfikacji z tytułów wnioski się nie zmieniają.
- Kontrola 50 losowych adresów: 48/48 zgodnych (asystent AI, nie człowiek). Wnioskowanie po pytaniach, 95% CI, protokół zapisany przed danymi.

CO WIEMY

- Język pytania może silnie zmieniać zestaw cytowanych domen; skala zależy od systemu.
- W OpenAI rozrzut powtórzeń jest tak duży jak efekt języka: jedno zapytanie to nie pomiar.
- Dwa dni później, z lokalizacją Polska i bez: w całej próbie nie wykazano jej wpływu, a Perplexity znów +94 p.p. Wyjątek eksploracyjny: porady zakupowe w OpenAI, +25 p.p. polskich źródeł z lokalizacją PL.

CZEGO NIE WIEMY

- Czy zmiana źródeł poprawia, czy pogarsza jakość odpowiedzi.
- Skąd się bierze (indeks, ranking, model) i czy aplikacje działają jak API.
- Czy wynik przenosi się na inne pytania i języki: 30 pytań autorskich, jedna para języków.
- Czy stabilność Perplexity to po części cache: po 2 dniach wspólnych domen 82–85%.

DLACZEGO TO WAŻNE

Nowość: efekt języka porównujemy z naturalną zmiennością tego samego systemu, mierzoną w 5 powtórzeniach. Wyszukiwarka AI wybiera, które instytucje i strony pokaże jako źródło wiedzy, więc ocena widoczności w AI powinna uwzględniać język odbiorcy, powtórzenia i brakujące cytowania.

1. Kirsten E. i in. Characterizing Web Search in the Age of Generative AI. Findings of ACL 2026.
2. Ki D. i in. Linguistic Nepotism: Trading-off Quality for Language Preference in Multilingual RAG. ICML 2026.
3. Martinez O. Optimizing Visibility in Generative Engines: A Critical Survey of Generative Engine Optimization (2023–2026). arXiv:2607.14035.
4. Joulin A. i in. Bag of Tricks for Efficient Text Classification. EACL 2017.

Dane, kod i protokół
github.com/MaciejZet/daiversity-2026-ai-search-language